

Redes Neuronales y Deep Learning para Visión Computacional

Curso de Inteligencia Artificial

Dr. Rubén Hernández Torres

7 de mayo de 2026

Introducción

¿Qué es una Red Neuronal?

Definición

Una red neuronal artificial es un modelo matemático inspirado en el cerebro humano, compuesto por capas de neuronas interconectadas que transforman datos de entrada en salidas.


¿Qué es una Red Neuronal?

Definición

Una red neuronal artificial es un modelo matemático inspirado en el cerebro humano, compuesto por capas de neuronas interconectadas que transforman datos de entrada en salidas.

- Modelo paramétrico: aprende pesos y sesgos
- Aproximador universal de funciones
- Base de múltiples algoritmos de visión computacional

¿Qué es una Red Neuronal?




Modelo Matemático

Neurona Artificial

Neurona Artificial

Las neuronas son las unidades de procesamiento se denominan neuronas. Cada neurona recibe entradas de otros nodos y genera una salida simple escalar que depende de la información local disponible, guardada internamente o que llega a través de las conexiones con pesos.



Modelo

$$z = \mathbf{w}^T \mathbf{x} + b$$

$$a = \sigma(z)$$

- $\mathbf{x}$: vector de entrada
- $\mathbf{w}$: pesos
- b : sesgo
- σ : función de activación

Neurona Artificial

Modelo

$$z = \mathbf{w}^T \mathbf{x} + b$$

$$a = \sigma(z)$$

- $\mathbf{x}$: vector de entrada
- $\mathbf{w}$: pesos
- b : sesgo
- σ : función de activación

Interpretación

Cada neurona define un **hiperplano** en el espacio de características.

Función de Activación

Es una regla que logra establecer el efecto de la entrada total en la activación de la unidad k , añadiendo no linealidad al modelo.

- Sigmoides:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

- ReLU:

$$\text{ReLU}(x) = \max(0, x)$$


- Tanh:

$$\tanh(x)$$

Activation Functions


Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$




tanh

$$\tanh(x)$$




ReLU

$$\max(0, x)$$



Leaky ReLU

$$\max(0.1x, x)$$




Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$


ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$



Feedforward

Feedforward



Propagación hacia adelante (Feedforward)

Definición

Proceso mediante el cual la información fluye desde la entrada hasta la salida.

Propagación hacia adelante (Feedforward)

Definición

Proceso mediante el cual la información fluye desde la entrada hasta la salida.

Forma vectorial

$$\mathbf{a}^{(l)} = \sigma(\mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)})$$

- l : capa
- $\mathbf{W}$: matriz de pesos
- $\mathbf{a}$: activaciones

Función de Costo

Definición

Mide el error entre la predicción del modelo y el valor real.

Definición

Mide el error entre la predicción del modelo y el valor real.

- Error cuadrático medio:

$$J = \frac{1}{2} \|\mathbf{y} - \hat{\mathbf{y}}\|^2$$

- Entropía cruzada:

$$J = - \sum y \log(\hat{y})$$

Objetivo

Minimizar J ajustando los parámetros del modelo

Backpropagation

Definición

Algoritmo para calcular gradientes de la función de costo respecto a los parámetros.

Backpropagation

Definición

Algoritmo para calcular gradientes de la función de costo respecto a los parámetros.

Regla de la cadena

$$\frac{\partial J}{\partial w} = \frac{\partial J}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial w}$$

- Propaga el error hacia atrás
- Permite actualización eficiente

Gradiente y Optimización

Definición

Vector de derivadas parciales de la función de costo:

$$\nabla J(\theta)$$

Definición

Vector de derivadas parciales de la función de costo:

$$\nabla J(\theta)$$

Interpretación

Dirección de máximo crecimiento del error

Regla de actualización

$$\theta := \theta - \eta \nabla J(\theta)$$


- η : tasa de aprendizaje
- Iterativo

Regla de actualización

$$\theta := \theta - \eta \nabla J(\theta)$$

- η : tasa de aprendizaje
- Iterativo
- Batch Gradient Descent
- Stochastic Gradient Descent (SGD)
- Mini-batch

Descenso del Gradiente



Interpretación Geométrica

Interpretación como Hiperplanos

Idea clave

Cada neurona define una frontera de decisión lineal:

$$\mathbf{w}^T \mathbf{x} + b = 0$$

Interpretación como Hiperplanos

Idea clave

Cada neurona define una frontera de decisión lineal:


$$\mathbf{w}^T \mathbf{x} + b = 0$$

- Composición de múltiples hiperplanos
- Permite modelar funciones no lineales

Importante

Las redes profundas generan particiones complejas del espacio.

Interpretación como Hiperplanos



Deep Learning

¿Qué es Deep Learning?

Definición

El **Deep Learning** es una subárea del aprendizaje automático basada en redes neuronales profundas (múltiples capas), capaces de aprender representaciones jerárquicas de los datos.

¿Qué es Deep Learning?

Definición

El **Deep Learning** es una subárea del aprendizaje automático basada en redes neuronales profundas (múltiples capas), capaces de aprender representaciones jerárquicas de los datos.

- Aprende características automáticamente (feature learning)
- Evita ingeniería manual de características
- Escalable a grandes volúmenes de datos

- Capas iniciales: características simples (bordes, texturas)
- Capas intermedias: patrones más complejos
- Capas profundas: conceptos abstractos

Representaciones Jerárquicas

- Capas iniciales: características simples (bordes, texturas)
- Capas intermedias: patrones más complejos
- Capas profundas: conceptos abstractos

Idea clave

Cada capa transforma los datos a un nuevo espacio de representación


Representaciones Jerárquicas

Progressive extraction of features by a Neural Network

Input image



Low Level Features



Lines & Edges

Mid Level Features




Eyes & Nose & Ears

High Level Features



Facial Structure



Clasificación de Modelos de Deep Learning

Idea General

Los modelos de Deep Learning pueden clasificarse según su arquitectura, flujo de información y tipo de datos que procesan.

Idea General

Los modelos de Deep Learning pueden clasificarse según su arquitectura, flujo de información y tipo de datos que procesan.

- Redes Feedforward (Fully Connected)
- Redes Convolucionales (CNN)
- Redes Recurrentes (RNN)
- Modelos Generativos (GANs, VAEs)

Sugerencia visual: Diagrama comparativo de arquitecturas

Tabla Comparativa de Arquitecturas

Modelo	Tipo de Datos	Dependencias	Uso Principal
Feedforward	Tabular / vectores	Ninguna	Clasificación básica
CNN	Imágenes	Locales espaciales	Visión computacional
RNN	Secuencias	Temporales	Series / video
GANs	Distribuciones	Generativas	Síntesis de datos

Idea clave: Cada arquitectura impone una **estructura inductiva** distinta sobre los datos.

Redes Feedforward (MLP)

Definición

Redes totalmente conectadas donde cada capa se conecta con la siguiente.

Redes Feedforward (MLP)

Definición

Redes totalmente conectadas donde cada capa se conecta con la siguiente.

- No explotan estructura espacial
- Operan sobre vectores planos

Redes Feedforward (MLP)

Definición

Redes totalmente conectadas donde cada capa se conecta con la siguiente.

- No explotan estructura espacial
- Operan sobre vectores planos

Uso en visión

- Clasificación simple con features preextraídas
- Baseline models

Limitación: No capturan correlaciones espaciales

Redes Convolucionales (CNN)

Definición

Redes que utilizan convoluciones para explotar la estructura espacial de las imágenes.

Redes Convolucionales (CNN)

Definición

Redes que utilizan convoluciones para explotar la estructura espacial de las imágenes.

- Filtros locales
- Compartición de pesos
- Invariancia a traslaciones

Redes Convolucionales (CNN)

Definición

Redes que utilizan convoluciones para explotar la estructura espacial de las imágenes.

- Filtros locales
- Compartición de pesos
- Invariancia a traslaciones

Aplicaciones

- Clasificación de imágenes
- Detección de objetos
- Segmentación

Sugerencia visual: Filtros convolucionales

Redes Recurrentes (RNN)

Definición

Modelos diseñados para procesar datos secuenciales mediante estados internos.

Redes Recurrentes (RNN)

Definición

Modelos diseñados para procesar datos secuenciales mediante estados internos.

$$h_t = f(x_t, h_{t-1})$$

Redes Recurrentes (RNN)

Definición

Modelos diseñados para procesar datos secuenciales mediante estados internos.

$$h_t = f(x_t, h_{t-1})$$

- Memoria temporal
- Dependencias a largo plazo (LSTM, GRU)

Redes Recurrentes (RNN)

Definición

Modelos diseñados para procesar datos secuenciales mediante estados internos.

$$h_t = f(x_t, h_{t-1})$$

- Memoria temporal
- Dependencias a largo plazo (LSTM, GRU)

Uso en visión

- Análisis de video
- Captioning de imágenes

Limitación: Difícil entrenamiento (gradientes)

Modelos Generativos (GANs)

Definición

Modelo compuesto por dos redes:

- Generador (G)
- Discriminador (D)

Modelos Generativos (GANs)

Definición

Modelo compuesto por dos redes:

- Generador (G)
- Discriminador (D)

Objetivo

$$\min_G \max_D V(D, G)$$

Modelos Generativos (GANs)

Definición

Modelo compuesto por dos redes:

- Generador (G)
- Discriminador (D)

Objetivo

$$\min_G \max_D V(D, G)$$

- Generación de imágenes realistas
- Aumento de datos

Sugerencia visual: Esquema generador vs discriminador

Comparación en Visión Computacional

Arquitectura	Fortalezas	Debilidades	Ejemplo en visión
MLP	Simple	Ignora estructura	Clasificación básica
CNN	Espacial	Costosa	Reconocimiento de objetos
RNN	Temporal	Inestable	Video / tracking
GAN	Generación	Difícil de entrenar	Síntesis de imágenes

Idea clave: La elección depende del **tipo de estructura en los datos**.

- CNN → análisis espacial (imagen estática)
- RNN → dinámica temporal (video)
- GAN → generación / aumento de datos
- MLP → capas finales (clasificadores)

- CNN → análisis espacial (imagen estática)
- RNN → dinámica temporal (video)
- GAN → generación / aumento de datos
- MLP → capas finales (clasificadores)

Importante

En sistemas modernos, estas arquitecturas suelen combinarse.

Sugerencia visual: Pipeline híbrido (CNN + RNN)

Consideraciones en Visión Computacional

- Representación de imágenes como tensores
- Normalización de datos
- Sobreajuste (overfitting)
- Regularización (L2, dropout)
- Inicialización de pesos
- Escalabilidad computacional

Aspectos Críticos

- Representación de imágenes como tensores
- Normalización de datos
- Sobreajuste (overfitting)
- Regularización (L2, dropout)
- Inicialización de pesos
- Escalabilidad computacional

Importante

El preprocesamiento es clave para el desempeño

Introducción a PyTorch

¿Qué es PyTorch?

Definición

Framework de deep learning basado en tensores con soporte de GPU.

- Computación dinámica (define-by-run)
- Autograd (diferenciación automática)

Definición

Estructura de datos multidimensional:

```
torch.Tensor
```

- Generalización de matrices
- Soporte para GPU

Sugerencia visual: Ejemplos de tensores 1D, 2D, 3D

Dataset

Define cómo acceder a los datos

Datasets y Dataloaders

Dataset

Define cómo acceder a los datos

Dataloader

Permite:

- Batching
- Shuffling
- Paralelismo

Sugerencia visual: Pipeline de datos

Definición

Agrupación de múltiples muestras:

$$(X, Y)$$

- Mejora eficiencia computacional
- Estabiliza entrenamiento

- Forward pass
- Cálculo de pérdida
- Backward pass
- Actualización de parámetros

- Forward pass
- Cálculo de pérdida
- Backward pass
- Actualización de parámetros

Autograd

Calcula automáticamente los gradientes

Cierre

- Redes neuronales = modelos paramétricos potentes
- Backpropagation permite aprendizaje eficiente
- Interpretación geométrica ayuda a comprensión
- PyTorch facilita implementación práctica

¿Preguntas?