

Segmentación y Reconocimiento en Visión por Computadora

Visión Artificial y Procesamiento de Imágenes

Dr. Rubén Hernández Torres

12 de abril de 2026

Segmentación de Imágenes

¿Qué es Segmentación?

Definición

La **segmentación** es el proceso de particionar una imagen I en regiones disjuntas $\{R_k\}$ tales que:

$$\bigcup_k R_k = I, \quad R_i \cap R_j = \emptyset$$

Objetivo

Aislar estructuras u objetos homogéneos para análisis posterior (detección/clasificación).

Definición

Separación basada en intensidad:

$$S(x) = 1 \text{ si } I(x) \geq T, 0 \text{ en otro caso}$$

Métodos

Umbral global, adaptativo, Otsu.

Definición

Detección de discontinuidades en el gradiente:

$$\nabla I = (\partial_x I, \partial_y I)$$

Idea

Los bordes delimitan regiones.

Definición

Expansión de regiones desde semillas.

Criterio

$$|I(x) - I(s)| < \epsilon$$

Clustering para Segmentación

Definición

Agrupación de píxeles en el espacio de características.

Ejemplo

K-means sobre píxeles.


Watershed

Definición

Segmentación basada en topografía de la imagen.

Idea

Cuencas definen regiones.



Idea central

Interpretar la imagen como una superficie topográfica donde:

- Intensidad baja → valles
- Intensidad alta → montañas

Proceso

Se simula una inundación desde los mínimos locales.

Resultado

Las líneas donde el agua se encuentra → fronteras de segmentación.

Watershed: Flujo del Algoritmo

Entrada

Imagen original o su gradiente $G(x, y)$.

Pasos

1. Identificar mínimos locales
2. Inundar progresivamente
3. Detectar colisiones entre regiones

Salida

Mapa de etiquetas (segmentación completa).

Definición

Segmentación guiada mediante regiones iniciales (semillas).

Tipos

- Marcadores de objeto
- Marcadores de fondo

Ventaja

Controla el proceso y evita errores del método clásico.

Problema: Sobre-segmentación

Causa

Presencia de muchos mínimos locales debido a ruido.

Consecuencia

Demasiadas regiones pequeñas sin significado semántico.

Ejemplo

Texturas generan múltiples cuencas irrelevantes.

Preprocesamiento

- Suavizado (Gaussian Blur)
- Filtros morfológicos

Estrategias

- Watershed con marcadores
- Uso de transformada de distancia

Flujo típico

1. Binarización (threshold)
2. Eliminación de ruido
3. Transformada de distancia
4. Obtención de marcadores
5. Aplicación de Watershed

Clave

La calidad de los marcadores determina el resultado.

Aplicaciones

- Separación de objetos en contacto
- Segmentación médica (células, tejidos)
- Conteo de objetos

Ventaja

No requiere entrenamiento (método clásico).

Segmentación vs Detección

Segmentación

Etiqueta por píxel.

Detección

Localización de objetos.

Relación

Preprocesamiento clave para clasificación.

Fundamentos

Definición

Un **patrón** es un vector de características:

$$\mathbf{x} = [x_1, x_2, \dots, x_d] \in \mathbb{R}^d$$

que representa cuantitativamente un objeto o región de una imagen.

Ejemplo en visión

Histograma de intensidades, descriptores SIFT, ORB.

Definición

Una **clase** es una categoría discreta asociada a un patrón:

$$y \in \{1, \dots, K\}$$

Interpretación

Agrupar patrones con propiedades similares en el espacio de características.

Definición

Un **clasificador** es una función:

$$f: \mathbb{R}^d \rightarrow \mathcal{Y}$$


que asigna un patrón a una clase.

Objetivo

Aproximar la distribución posterior:

$$P(y|\mathbf{x})$$

Clasificador



Aprendizaje Supervisado

Aprendizaje Supervisado

Proceso de aprendizaje a partir de un conjunto etiquetado:

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$$

Objetivo

Minimizar una función de pérdida:

$$\mathcal{L}(y, f(x))$$

Entrenamiento

Ajuste del modelo a los datos.

Validación

Selección de hiperparámetros.

Prueba

Estimación del error de generalización.

Definición

Clasificador basado en vecinos más cercanos:

$$y = \text{mode}(\mathcal{N}_k(x))$$

Características

No paramétrico, basado en distancia.

Definición

Modelo que encuentra un hiperplano óptimo que separa clases.

Formulación

$$\text{mín } \frac{1}{2} ||w||^2$$

Definición

Método que combina múltiples clasificadores débiles.

Modelo

$$F(x) = \sum \alpha_m h_m(x)$$

Aprendizaje No Supervisado

Aprendizaje No Supervisado

Aprendizaje sin etiquetas:

$$\mathcal{D} = \{x_i\}$$

Objetivo

Descubrir estructura en los datos.

Definición

Agrupar datos en conjuntos homogéneos.

Ejemplo

K-means:

$$\text{mín} \sum ||x_i - \mu_k||^2$$

Definición

Técnica de reducción de dimensionalidad.

Objetivo

Maximizar varianza proyectada.

Evaluación

Matriz de Confusión

Definición

Tabla que resume predicciones vs valores reales.

Componentes

TP, TN, FP, FN

Accuracy

$$\frac{TP + TN}{N}$$

Precision

$$\frac{TP}{TP + FP}$$

Recall

$$\frac{TP}{TP + FN}$$

¿Por qué necesitamos métricas?

- No basta con la exactitud (*accuracy*)
- En problemas de visión:
 - Clases desbalanceadas (ej: detección de defectos)
 - Interesa más detectar positivos correctamente
- Usamos métricas basadas en la matriz de confusión:
 - Verdaderos Positivos (TP)
 - Falsos Positivos (FP)
 - Falsos Negativos (FN)
 - Verdaderos Negativos (TN)

Precision

Definición:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Interpretación:

- De todas las predicciones positivas, ¿cuántas son correctas?

En visión por computadora:

- Ejemplo: detección de tumores
- Alta precisión = pocas falsas alarmas

Intuición:

“Si el modelo dice que hay un objeto, ¿puedo confiar en él?”

Recall (Sensibilidad)

Definición:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Interpretación:

- De los positivos reales, ¿cuántos detectó el modelo?

En visión por computadora:

- Ejemplo: detección de peatones
- Alto recall = pocos casos perdidos

Intuición:

“¿El modelo está dejando pasar objetos importantes?”

Precision vs Recall

Relación clave:

- Existe un **trade-off**
- Mejorar precision puede reducir recall y viceversa

Ejemplo:

- Detector muy estricto:
 - Alta precision
 - Bajo recall
- Detector permisivo:
 - Alto recall
 - Baja precision

Idea clave

Depende de la aplicación: medicina, seguridad, conducción autónoma, etc.

Definición:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Interpretación:

- Media armónica entre precision y recall
- Penaliza valores extremos

¿Cuándo usarlo?

- Clases desbalanceadas
- Cuando precision y recall son igual de importantes

Intuición

Un modelo solo es bueno si ambos (precision y recall) son altos

Definición:

- Número de muestras reales por clase

Interpretación:

- Indica cuántos ejemplos tiene cada clase en el dataset

Importancia:

- Permite interpretar correctamente las métricas
- Evita conclusiones engañosas

Advertencia

Un buen F1-score en una clase con bajo support puede no ser confiable

Definición

División del dataset en subconjuntos (folds).

Objetivo

Reducir varianza en la estimación.

Features en Imágenes

Feature

Función que transforma una imagen en vector:

$$\mathbf{x} = \phi(I)$$

Definición

Proceso de elegir características relevantes.

Criterios

Discriminabilidad, redundancia, robustez.

Características en Machine Learning para Imágenes

¿Por qué usar características (features)?

- Los modelos de ML clásicos (SVM, KNN, Random Forest) no trabajan directamente con imágenes crudas.
- Es necesario transformar la imagen en un vector de características.
- Buenas características:
 - Invariantes a iluminación y escala
 - Discriminativas
 - Compactas
- Pipeline típico:

Pipeline

Imagen → Extracción de características → Clasificador

Histogram of Oriented Gradients (HOG)

- Una de las características más usadas con SVM.
- Captura la estructura local de bordes y gradientes.
- Muy utilizada en:
 - Detección de peatones
 - Reconocimiento de objetos
- Idea clave:

Idea

Histogramas de orientaciones de gradiente en celdas locales

Pipeline de HOG

1. Cálculo de gradientes (Sobel)
2. División en celdas (ej. 8×8)
3. Cálculo de histogramas de orientación
4. Normalización por bloques
5. Concatenación del vector final

Ventaja

Robusto a cambios de iluminación y pequeñas deformaciones

SIFT (Scale-Invariant Feature Transform)

- Detecta puntos clave invariantes a escala y rotación
- Describe cada punto con un vector de gradientes locales
- Muy robusto pero computacionalmente costoso

Uso común

Matching de imágenes, reconocimiento de objetos

- SURF: versión acelerada de SIFT
- ORB: alternativa eficiente y libre de patentes

ORB

- Combina FAST (detección) + BRIEF (descripción)
- Muy rápido
- Ideal para aplicaciones en tiempo real

LBP (Local Binary Patterns)

- Describe texturas locales
- Compara cada píxel con sus vecinos
- Genera un código binario

Aplicaciones

- Reconocimiento facial
- Clasificación de texturas

Características de Color

- Histogramas de color (RGB, HSV)
- Media y varianza por canal
- Momentos de color

Ventaja

Simple y eficientes

Limitación

No capturan información espacial

Bag of Visual Words (BoVW)

- Extensión del modelo Bag of Words (texto)
- Usa descriptores como SIFT u ORB
- Agrupa características usando clustering (K-means)

Idea

Imagen = histograma de "palabras visuales"

- Muy usado con SVM

Comparación de Características

Método	Invarianza	Costo	Uso típico
HOG	Media	Bajo	Detección
SIFT	Alta	Alto	Matching
ORB	Media	Muy bajo	Tiempo real
LBP	Baja	Muy bajo	Textura
Color	Baja	Muy bajo	Clasificación básica

Conclusión

- Las características son clave en ML clásico
- HOG + SVM sigue siendo un baseline fuerte
- Métodos como SIFT/ORB permiten matching robusto
- Hoy en día:

Tendencia

Deep Learning aprende automáticamente las características

Identificación

Identificación

Asignar una identidad única a un patrón.

Diferencia

Clasificación: clases finitas Identificación: entidades únicas

Resumen

- Representación (features)
- Modelado (clasificadores)
- Evaluación